

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 1

Praca z danymi medycznymi: import, przetwarzanie i analiza

Wariant: **1 (fallback z 8)** — **dataset 8: Prostate cancer (synth)**

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	7
10	Wnioski	7

1 Cel zadania

Zapoznanie z procesem pracy z danymi medycznymi: importem, czyszczeniem, uzupełnianiem braków, standaryzacją, analizą statystyczną oraz wizualizacją danych pacjentów. W wariancie wykorzystano kohortę pacjentów onkologicznych (prostate cancer, syntetyczna).

2 Opis problemu

Dane medyczne są wrażliwe, niejednorodne i często niekompletne. Zadaniem jest ich przygotowanie do analizy oraz dalszego modelowania, w tym diagnoza braków, konwersja typów, standaryzacja zmiennych ilościowych oraz weryfikacja zależności między cechami a stanem klinicznym pacjenta.

3 Opis danych

Zbiór syntetyczny imitujący kohortę prostate-cancer-survival (N=600). Zmienne: `age`, `psa`, `gleason_score`, `tumor_stage`, `treatment`, `comorbidities`, `survival_months`, `survived`. Braki danych wprowadzono losowo w kolumnie `psa` (5%).

4 Opis metod

Zastosowano: (a) uzupełnianie braków medianą dla `psa`; (b) standaryzację Z-score zmiennych ilościowych; (c) statystyki opisowe (średnia, mediana, odch. std., min, max); (d) wizualizację rozkładów (histogramy, wykresy pudełkowe) i zależności (macierz korelacji Pearsona); (e) prostą regresję logistyczną z wagami klas jako linię bazową dla zadania predykcji przeżycia.

5 Opis implementacji

Pełna implementacja w `lab1/lab1_solution.py`. Kluczowe etapy: `synth_prostate_cancer_dataset` – generator danych; `preprocess` – czyszczenie i standaryzacja; `descriptive_stats` – statystyki opisowe; `plot_*` – wizualizacje; `baseline_model` – regresja logistyczna. Ścieżki względne, brak hardkodów.

6 Obliczenia

Liczności braków przed i po imputacji medianą:

kolumna	braki przed	braki po
patient_id	0	0
age	0	0
psa	30	0
gleason_score	0	0
tumor_stage	0	0
treatment	0	0
comorbidities	0	0
survival_months	0	0
survived	0	0

Tabela 1: Braki danych przed i po imputacji.

Statystyki opisowe zmiennych ilościowych:

zmienna	średnia	odch. std.	min	mediana	max
age	68.0470	8.9920	45.0000	68.0000	92.0000
psa	8.9200	7.3970	1.0400	6.8800	67.4200
gleason_score	7.5100	1.0870	6.0000	7.0000	10.0000
comorbidities	1.3130	1.1740	0.0000	1.0000	6.0000
survival_months	72.5800	38.1970	4.6000	67.9000	238.8000
survived	0.8680	0.3380	0.0000	1.0000	1.0000

Tabela 2: Statystyki opisowe zmiennych ilościowych.

7 Wyniki

Liczności kategorii `tumor_stage`:

kategoria	liczność	odsetek (%)
T2	226	37.6700
T1	192	32.0000
T3	150	25.0000
T4	32	5.3300

Tabela 3: Liczność kategorii `tumor_stage`.


Liczności kategorii `treatment`:

kategoria	liczność	odsetek (%)
radiation	202	33.6700
surgery	179	29.8300
hormonal	143	23.8300
watch	76	12.6700


Tabela 4: Liczność kategorii `treatment`.

Linia bazowa (regresja logistyczna): **accuracy** = 0.740, **ROC AUC** = 0.754 (zbiór testowy N=150).


8 Wykresy




Rysunek 1: Histogramy zmiennych ilościowych.



Rysunek 2: Wykresy pudełkowe zmiennych ilościowych.



Rysunek 3: Macierz korelacji Pearsona.



Rysunek 4: Licznosci kategorii tumor_stage i treatment.

9 Interpretacja wyników

Histogramy pokazują typowe rozkłady: wiek skupiony wokół 68 lat, PSA prawoskośny (rozkład logarytmiczno-normalny), Gleason score skoncentrowany w okolicy 7. Macierz korelacji ujawnia umiarkowaną dodatnią zależność wieku i Gleason score z ryzykiem zgonu (ujemna korelacja ze zmienną `survived`). Licznosci kategorii pokazują dominację stadium T1–T2 oraz terapii operacyjnej i radioterapii. Linia bazowa logistic regression osiąga $AUC = 0.754$, co potwierdza spójność danych i sensowność wybranych cech.

10 Wnioski

Etap importu, czyszczenia i analizy statystycznej został zrealizowany. Wprowadzono kontrolowane braki, które uzupełniono medianą bez utraty rekordów. Standaryzacja Z-score umożliwia porównywalność cech o różnych skalach. Analiza wskazuje, że PSA, Gleason score i stadium guza są informatywnymi predyktorami przeżycia, co stanowi punkt wyjścia dla bardziej zaawansowanych modeli (kolejne laboratoria).