

# Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 2

*Modele klasyfikacji: regresja logistyczna na danych klinicznych*

Wariant: 1 (fallback z 8) — klasyfikacja przeżycia (prostate cancer)

Jakub Jurzak 59099

07.05.2026

## Spis treści

|    |                       |   |
|----|-----------------------|---|
| 1  | Cel zadania           | 3 |
| 2  | Opis problemu         | 3 |
| 3  | Opis danych           | 3 |
| 4  | Opis metod            | 3 |
| 5  | Opis implementacji    | 3 |
| 6  | Obliczenia            | 3 |
| 7  | Wyniki                | 4 |
| 8  | Wykresy               | 5 |
| 9  | Interpretacja wyników | 8 |
| 10 | Wnioski               | 8 |

## 1 Cel zadania

Budowa i ewaluacja prostego modelu klasyfikacyjnego (regresja logistyczna) rozpoznającego stan kliniczny pacjenta na podstawie danych z lab1 (syntetyczna kohorta prostate cancer).

## 2 Opis problemu

Predykcja przeżycia pacjenta (`survived=1`) na bazie cech: `age`, `psa`, `gleason_score`, `comorbidities`, `tumor_stage`, `treatment`. Klasy są niezbilansowane — stosujemy `class_weight=balanced`.

## 3 Opis danych

Zbiór z lab1: `prostate_cancer_synth.csv` ( $N = 600$ ). Braki w kolumnie `psa` uzupełniono medianą. Cechy kategoryczne zakodowano OHE (drop first). Wszystkie cechy ilościowe wystandaryzowane (`StandardScaler`).

## 4 Opis metod

Regresja logistyczna z regularyzacją L2 (`lbfgs`, `max_iter=2000`) i wagami klas. Podział train/test 75/25 ze stratyfikacją po etykiecie. Miary: `accuracy`, `precision`, `recall`, `F1`, `ROC AUC`. Diagnostyka: krzywa ROC, krzywa PR, macierz pomyłek, ranking współczynników.

## 5 Opis implementacji

Plik `lab2/lab2_solution.py`. Funkcje `prepare`, `evaluate`, `plot_*` oraz `main` oddzielają etapy preprocessingu, treningu, ewaluacji i wizualizacji. Brak hardkodów, ścieżki względne.

## 6 Obliczenia

Pomocnicze obliczenie odds ratio dla każdej cechy:  $OR_j = \exp(\beta_j)$ . Dla cech wystandaryzowanych  $\beta_j$  interpretujemy jako efekt zmiany o jedno odchylenie standardowe.

| cecha               | współczynnik | odds_ratio |
|---------------------|--------------|------------|
| treatment_surgery   | 0.1190       | 1.1270     |
| comorbidities       | -0.0190      | 0.9810     |
| treatment_radiation | -0.0520      | 0.9490     |
| tumor_stage_T2      | -0.1330      | 0.8750     |
| tumor_stage_T4      | -0.2930      | 0.7460     |
| psa                 | -0.3230      | 0.7240     |
| treatment_watch     | -0.4260      | 0.6530     |
| age                 | -0.4440      | 0.6410     |
| tumor_stage_T3      | -0.4900      | 0.6120     |
| gleason_score       | -0.8450      | 0.4300     |

**Tabela 1:** Współczynniki regresji logistycznej i odds ratio.


## 7 Wyniki

Miary jakości na zbiorze testowym ( $N_{test} = 150$ ):


| miara     | wartość |
|-----------|---------|
| accuracy  | 0.740   |
| precision | 0.933   |
| recall    | 0.754   |
| F1        | 0.834   |
| ROC AUC   | 0.754   |

**Tabela 2:** Miary jakości klasyfikacji.


## 8 Wykresy




Rysunek 1: Krzywa ROC.



**Rysunek 2:** Krzywa precision-recall.



**Rysunek 3:** Macierz pomyłek.



Rysunek 4: Współczynniki regresji logistycznej.

## 9 Interpretacja wyników

Model osiąga  $\text{ROC AUC} = 0.754$ ,  $\text{F1} = 0.834$ , co świadczy o zauważalnej zdolności separacji klas. Ranking współczynników wskazuje, że Gleason score, PSA i wiek pacjenta zwiększają ryzyko zgonu (ujemny wpływ na `survived=1`), natomiast leczenie operacyjne i radioterapia wpływają korzystnie. Krzywa precision-recall potwierdza, że dobór progu decyzyjnego może istotnie zmieniać kompromis między wykrywalnością a precyzją.

## 10 Wnioski

Regresja logistyczna na omawianym zbiorze stanowi solidną linię bazową: interpretowalna (wagi i OR), szybka, dobrze skalibrowana po standaryzacji. Aby poprawić jakość warto rozważyć: (a) modele drzewiaste (np. random forest, gradient boosting) — następne ćwiczenia; (b) dodatkowe cechy z domeny klinicznej; (c) optymalizację progu klasyfikacji pod konkretną miarę kliniczną.