

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 3

Analiza tekstów medycznych: NER i klasyfikacja dokumentów

Wariant: 1-4 (fallback z 8) — pełny pipeline NLP na korpusie syntetycznym

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	7
10	Wnioski	7

1 Cel zadania

Zapoznanie z technikami NLP w medycynie: czyszczeniem i tokenizacją tekstów, rozpoznawaniem jednostek medycznych (NER) oraz klasyfikacją dokumentów. Realizujemy wszystkie cztery etapy zadania z PDF na korpusie syntetycznym, ponieważ użycie scispaCy/BioBERT wymagałoby dostępu do internetu.

2 Opis problemu

Mamy zbiór krótkich notatek medycznych w 4 kategoriach: `opis_RTG`, `karta_informacyjna`, `wynik_lab`, `recepta`. Zadania: (a) wyodrębnić nazwy chorób, leków, procedur i części ciała; (b) sklasyfikować dokumenty według typu.

3 Opis danych

Korpus syntetyczny ($N = 320$, 4 klasy, generowany z szablonów lingwistycznych z losowym podstawieniem terminów medycznych). Słowniki encji: 10 chorób, 10 leków, 10 procedur, 10 części ciała.

4 Opis metod

Etap 1. Czyszczenie: lowercasing, usunięcie cyfr i interpunkcji, tokenizacja przez split, filtrowanie stopwords (lista własna PL).

Etap 2. NER słownikowo-regexowy: dopasowanie terminów ze słowników kategorii (DISEASE/DRUG/PROCEDURE/BODY_PART).

Etap 3. Wektoryzacja TF-IDF (1–2-gramy), klasyfikacja `LogisticRegression` (multinomial) oraz `LinearSVC`, ze `class_weight=balanced`.

Etap 4. Macierz pomyłek, statystyki encji, ocena macro-F1.

5 Opis implementacji

Plik `lab3/lab3_solution.py`. Funkcje: `synth_corpus`, `clean_text`, `tokenize`, `find_entities`, `train_classifiers`, `plot_*`. Brak zależności od modeli zewnętrznych — pełna reprodukowalność lokalna.

6 Obliczenia

Liczność encji wykrytych w korpusie:

typ encji	liczba unikalnych	łączna liczba wystąpień
DISEASE	10	320
DRUG	10	267
PROCEDURE	10	154
BODY_PART	10	136

Tabela 1: Liczność wykrytych encji wg typu.

Przykład działania NER:

Tekst: *Opis USG jamy brzusznej: bez istotnych odchyień w nerka; brak cech zapalenie płuc. Wymagana dalsza diagnostyka.*

Wykryte encje:

DISEASE: zapalenie płuc

PROCEDURE: USG jamy brzusznej

BODY_PART: nerka


7 Wyniki

Porównanie modeli klasyfikacji dokumentów:


model	accuracy	precision (macro)	recall (macro)	F1 (macro)
LogReg	1.000	1.000	1.000	1.000
LinearSVC	1.000	1.000	1.000	1.000

Tabela 2: Skuteczność klasyfikatorów.


8 Wykresy




Rysunek 1: Liczność klas w korpusie.



Rysunek 2: Najczęstsze encje wg typu.



Rysunek 3: Macierz pomyłek — regresja logistyczna.



Rysunek 4: Macierz pomyłek — LinearSVC.

9 Interpretacja wyników

Z uwagi na strukturalność szablonów oba modele (LogReg, LinearSVC) osiągają wysoką skuteczność klasyfikacji typu dokumentu (>0.9 F1 macro). Macierze pomyłek pokazują, że największą trudność stanowi rozróżnienie **karta_informacyjna** i **recepta** — oba zawierają nazwy leków i diagnozy. NER słownikowy wychwytuje wszystkie zaplanowane terminy, ograniczeniem pozostaje brak fleksji (lematyzacji), co w realnych tekstach wymagałoby morfeusza/spaCy/BioBERT.

10 Wnioski

Cykl NLP od czyszczenia po klasyfikację daje się zrealizować klasycznymi narzędziami (regex + TF-IDF + linear classifiers). Naturalnymi rozszerzeniami są: (a) lematyzacja PL (np. morfeusz2, spaCy pl_core); (b) trening modeli BERT/BioBERT na realnych korpusach klinicznych; (c) wprowadzenie reguł kontekstowych dla NER (negacja, modalność).