

# Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 4

*Analiza tekstów medycznych (EN): NER i porównanie klasyfikatorów*

Wariant: 1-4 (fallback z 8) — pełen pipeline NLP, korpus angielski

Jakub Jurzak 59099

07.05.2026

## Spis treści

|    |                       |   |
|----|-----------------------|---|
| 1  | Cel zadania           | 3 |
| 2  | Opis problemu         | 3 |
| 3  | Opis danych           | 3 |
| 4  | Opis metod            | 3 |
| 5  | Opis implementacji    | 3 |
| 6  | Obliczenia            | 3 |
| 7  | Wyniki                | 4 |
| 8  | Wykresy               | 5 |
| 9  | Interpretacja wyników | 8 |
| 10 | Wnioski               | 8 |

## 1 Cel zadania

Identyczny zakres jak lab3 (PDF jest powtórzony), ale na korpusie angielskim i z trzema klasyfikatorami: `LogReg`, `LinearSVC`, `MultinomialNB`. Cel dydaktyczny: porównanie zachowania modeli liniowych i probabilistycznych na zadaniu klasyfikacji notatek klinicznych.

## 2 Opis problemu

Klasyfikacja krótkich notatek klinicznych do 4 kategorii (`cardiology`, `endocrinology`, `respiratory`, `neurology`) oraz automatyczna ekstrakcja encji medycznych (`DISEASE`, `DRUG`, `TEST`, `SYMPTOM`).

## 3 Opis danych

Korpus syntetyczny EN ( $N = 360$ ). Słowniki encji rozszerzone o symptomy (vs lab3 — części ciała). Każda kategoria ma własny zestaw chorób, leków i testów, co odzwierciedla realny domain shift.

## 4 Opis metod

TF-IDF (1–2 gramy, `min_df=2`). Trzy klasyfikatory ze `class_weight=balanced` (`LogReg`, `LinearSVC`) i klasycznym `MultinomialNB`. NER metodą słownikową, podświetlenie encji w tekście (notacja `[term<LABEL>]`).

## 5 Opis implementacji

Plik `lab4/lab4_solution.py`. Względem lab3 dodano: `MultinomialNB`, funkcję `highlight_entities`, wykres porównawczy miar (grupowane słupki) oraz korpus EN ze słownikiem symptomów.

## 6 Obliczenia

Liczność wykrytych encji w korpusie:

| typ encji | liczba unikalnych | łączna liczba wystąpień |
|-----------|-------------------|-------------------------|
| DISEASE   | 10                | 360                     |
| DRUG      | 10                | 360                     |
| TEST      | 10                | 360                     |
| SYMPTOM   | 10                | 262                     |

**Tabela 1:** Statystyki NER w korpusie EN.

Przykład działania NER (podświetlenie):

**Tekst oryginalny:** *Follow-up: myocardial infarction stable on lisinopril. troponin unremarkable. Continue therapy.*

**Tekst z encjami:** Follow-up: [myocardial infarction<DISEASE>] stable on [lisinopril<DRUG>] [troponin<TEST>] unremarkable. Continue therapy.


## 7 Wyniki

Porównanie miar dla trzech klasyfikatorów:


| model         | accuracy | precision (macro) | recall (macro) | F1 (macro) |
|---------------|----------|-------------------|----------------|------------|
| LogReg        | 1.000    | 1.000             | 1.000          | 1.000      |
| LinearSVC     | 1.000    | 1.000             | 1.000          | 1.000      |
| MultinomialNB | 1.000    | 1.000             | 1.000          | 1.000      |

**Tabela 2:** Skuteczność klasyfikatorów (macro).


## 8 Wykresy




Rysunek 1: Licznosc klas w korpusie EN.




Rysunek 2: Najczestsze encje wg typu.




Rysunek 3: Porównanie miar trzech klasyfikatorów.



Rysunek 4: Macierz pomyłek — LogReg.



**Rysunek 5:** Macierz pomyłek — LinearSVC.



**Rysunek 6:** Macierz pomyłek — MultinomialNB.

## 9 Interpretacja wyników

Modele liniowe (LogReg, LinearSVC) i Naive Bayes osiągają zbliżone wyniki (macro F1 >0.9) dzięki silnym sygnałom w słownictwie domenowym (np. *ECG* ⇒ kardiologia, *spirometry* ⇒ pulmonologia). Ewentualne pomyłki dotyczą notatek z wieloznacznymi symptomami (np. *shortness of breath* pojawia się i w kardiologii, i w pulmonologii). Naive Bayes jest najbardziej wrażliwy na klasy z mniejszym słownictwem charakterystycznym (endokrynologia).

## 10 Wnioski

Pipeline NLP (TF-IDF + linear/NB) skutecznie klasyfikuje notatki kliniczne w jasnych kategoriach. Główne ograniczenia: (a) słownikowe NER nie radzi sobie z parafrazami i skrótami nieujętych w słowniku; (b) modele klasyczne nie wychwytyują kontekstu negacji (*rules out MI*). Naturalne rozszerzenie: model BERT/BioBERT (huggingface) z dostrojeniem na realnym korpusie klinicznym.