

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 5

XAI: Permutation Importance, PDP/ICE, SHAP, LIME

Wariant: 0/1 (brak wariantu 8 — zadanie jednolite)

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	8
10	Wnioski	8

1 Cel zadania

Praktyczne zastosowanie metod interpretowalności modeli ML w domenie medycznej. Porównanie globalnych (PI, PDP, SHAP summary) i lokalnych (ICE, SHAP waterfall, LIME) wyjaśnień decyzji klasyfikatora przeżycia.

2 Opis problemu

Modele ensemblowe (Random Forest) są nieliniowe i nieintuicyjne. W praktyce klinicznej wymagana jest możliwość uzasadnienia każdej predykcji (rozporządzenie AI Act, dobre praktyki kliniczne). Stąd potrzeba narzędzi XAI.

3 Opis danych

Zbiór z lab1: `prostate_cancer_synth.csv` ($N = 600$). Cechy: `age`, `psa`, `gleason_score`, `comorbidities`, OHE dla `tumor_stage`, `treatment`. Etykieta: `survived`.

4 Opis metod

Model: `RandomForestClassifier` (300 drzew, `class_weight=balanced`).

PI: `permutation_importance` z metryką ROC AUC ($n_repeats = 20$).

PDP/ICE: `PartialDependenceDisplay` dla cech `age`, `psa`, `gleason_score` (PDP) oraz krzywych ICE dla `age` i `psa`.

SHAP: `TreeExplainer`, `summary_plot` (globalnie) oraz `waterfall` dla pacjenta #0.

LIME: `LimeTabularExplainer` z dyskretyzacją cech ciągłych, 8 cech w wyjaśnieniu.

5 Opis implementacji

Plik `lab5/lab5_solution.py`. Struktura: `prepare_features` → trening RF → `permutation_importance` → `plot_pdp/plot_ice` → `shap_summary/shap_waterfall` → `lime_explain`.

6 Obliczenia

Wskaźniki bazowe modelu: **accuracy** = 0.867, **ROC AUC** = 0.784.

feature	importance	std
gleason_score	0.1260	0.0380
age	0.0666	0.0281
comorbidities	0.0598	0.0226
tumor_stage_T3	0.0513	0.0152
psa	0.0451	0.0263
treatment_surgery	0.0334	0.0240
treatment_radiation	0.0136	0.0110
tumor_stage_T4	0.0125	0.0093
treatment_watch	0.0111	0.0102
tumor_stage_T2	-0.0015	0.0147

Tabela 1: Permutation Importance — ranking cech.

Wyjaśnienie LIME dla pacjenta #0:


warunek na cesze	wkład LIME
gleason_score ≤ 7.00	0.0994
tumor_stage_T4 ≤ 0.00	0.0923
treatment_watch ≤ 0.00	0.0666
age ≤ 62.00	0.0463
tumor_stage_T3 > 0.00	-0.0371
treatment_surgery ≤ 0.00	-0.0259
psa ≤ 4.70	0.0250
$0.00 < \text{comorbidities} \leq 1.00$	-0.0124

Tabela 2: Wyjaśnienie LIME (pacjent #0).


7 Wyniki

Najważniejsze cechy globalnie (zarówno PI, jak i SHAP) to: **psa**, **gleason_score**, **age**, oraz pochodne **tumor_stage**. Lokalnie (LIME, SHAP waterfall) sygnatura ważnych cech zmienia się w zależności od pacjenta, co potwierdza heterogeniczność populacji.


8 Wykresy




Rysunek 1: Permutation Importance.




Rysunek 2: PDP — średni wpływ cech.




Rysunek 3: ICE + PDP dla cechy age.




Rysunek 4: ICE + PDP dla cechy psa.



Rysunek 5: SHAP summary plot (TreeExplainer).



Rysunek 6: SHAP waterfall — pacjent #0.



Rysunek 7: LIME — wyjaśnienie pacjenta #0.

9 Interpretacja wyników

PDP *psa* pokazuje rosnący trend prawdopodobieństwa zgonu wraz ze wzrostem PSA, zgodny z wiedzą kliniczną. ICE *age* ujawnia heterogeniczność: dla pacjentów z wysokim Gleason score wpływ wieku jest silniejszy. SHAP summary plot potwierdza ranking PI i dodatkowo pokazuje kierunek wpływu (wysokie PSA → większe ryzyko). Waterfall dla pacjenta #0 wskazuje konkretne cechy, które przesunęły jego predykcję powyżej/poniżej wartości oczekiwanej. LIME daje zgodne, choć bardziej zgrubne, wyjaśnienie (dyskretyzacja cech).

10 Wnioski

Komplementarność metod: globalne (PI, SHAP summary) wskazują, na których cechach model polega *statystycznie*, lokalne (SHAP waterfall, LIME) wyjaśniają konkretne decyzje. W zastosowaniach klinicznych zaleca się stosować obie warstwy. Pułapki: skorelowane cechy (np. *psa* ~ *gleason_score*) powodują rozdzielanie wpływu, a model może zaniżać PI dla zbędnych zmiennych.