

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 8

Aplikacja mobilna do monitorowania zdrowia (Streamlit)

Wariant: 8 — tryb anonimowy vs spersonalizowany

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	6
10	Wnioski	6

1 Cel zadania

Implementacja prototypu mobilnego monitora zdrowia w Streamlit, który wspiera dwa tryby pracy: anonimowy (jednorazowe pomiary, dane wspólne) i spersonalizowany (z `user_id`, historia per użytkownik). Porównanie skuteczności modelu globalnego i modeli lokalnych.

2 Opis problemu

Globalny model uczony na całej kohorcie może nie odpowiadać specyfice konkretnego użytkownika (różnice fizjologiczne, choroby przewlekłe). Z drugiej strony, model lokalny ma niewielką liczbę próbek. Należy ocenić, kiedy personalizacja przynosi korzyść.

3 Opis danych

Symulowane pomiary ($N = 410$): 5 użytkowników (spersonalizowani, 50–90 pomiarów każdy) + 60 pomiarów w trybie anonimowym. Cechy: `age`, `bmi`, `glucose`, `systolic_bp`, `diastolic_bp`. Etykieta dydaktyczna: $SBP \geq 140$ lub $DBP \geq 90$.

4 Opis metod

Etap 1. Aplikacja `app_v8.py` (Streamlit) z formularzem i toggle anon/personalized.

Etap 2. Statystyki opisowe populacji i per użytkownik, wykresy rozkładów i trendów.

Etap 3. Pipeline `ColumnTransformer` (`Imputer` + `Scaler`) + `LogisticRegression`. Model globalny (cała kohorta), modele lokalne (per `user_id`, jeśli $N_{user} \geq 20$).

Etap 4. Porównanie predykcji globalnego i lokalnego modelu dla tego samego pacjenta.

5 Opis implementacji

Pliki: `lab8/app_v8.py` (Streamlit, do uruchomienia komendą `python -m streamlit run lab8/app_v8.py`); `lab8/lab8_solution.py` (offline symulacja + trening + raport). Model globalny w `output/risk_model_global.joblib`, modele lokalne w `output/local_models/local_<user`

6 Obliczenia

Statystyki populacyjne:

zmienna	mean	std	min	50%	max
age	54.81	15.39	21.00	56.00	77.00
bmi	26.53	3.40	15.10	27.40	34.50
glucose	105.94	20.38	60.00	104.00	160.00
systolic_bp	137.06	19.43	85.00	137.00	181.00
diastolic_bp	84.89	10.10	58.00	86.00	110.00

Tabela 1: Statystyki populacyjne (cała kohorta).

Statystyki dla użytkownika U02:

zmienna	mean	std	min	50%	max
age	65.08	0.74	64.00	65.00	66.00
bmi	28.51	1.14	25.50	28.60	31.80
glucose	107.65	12.23	77.00	106.00	143.00
systolic_bp	148.55	8.86	128.00	149.00	167.00
diastolic_bp	90.72	6.41	75.00	90.00	110.00

Tabela 2: Statystyki użytkownika U02.

Metryki modeli:

model	n_train	n_test	accuracy	roc_auc	positive_rate_test
globalny (cała kohorta)	307	103	0.903	0.986	0.534
lokalny (U01)	45	15	1.000	NaN	0.000
lokalny (U02)	60	20	0.950	1.000	0.950
lokalny (U03)	0	0	NaN	NaN	NaN
lokalny (U04)	52	18	0.889	0.875	0.444
lokalny (U05)	67	23	1.000	NaN	1.000

Tabela 3: Metryki modelu globalnego i modeli lokalnych.

7 Wyniki


Wybrany pacjent (U02, pierwszy pomiar): age=65, bmi=27.0, glucose=101, SBP=149, DBP=88.

Predykcje obu modeli dla tego samego pomiaru:


model	P(podwyższone ryzyko)
globalny	0.968
lokalny (U02)	0.944

Tabela 4: Predykcje globalna vs lokalna.


8 Wykresy




Rysunek 1: Rozkłady cech wg trybu/użytkownika.



Rysunek 2: Trendy SBP/DBP per użytkownik.



Rysunek 3: Porównanie modeli: globalny vs lokalne.



Rysunek 4: Statystyki populacyjne vs użytkownik U02.

9 Interpretacja wyników

Model globalny uczy się na całej kohorcie ($N > 100$), więc jego ROC AUC jest stabilny. Modele lokalne mają mniej danych, ale są dopasowane do wzorców indywidualnych — dla użytkownika U02 (przewlekłe nadciśnienie) lokalna predykcja może różnić się od globalnej. Statystyki pokazują, że średnie SBP U02 jest istotnie wyższe niż populacyjne, więc model lokalny lepiej rozróżnia jego stany graniczne. W trybie anonimowym brak danych historycznych zmusza do wyłączenia korzystania z modelu globalnego.

10 Wnioski

Wybór trybu wpływa na model i jakość predykcji: tryb spersonalizowany pozwala na dopasowanie do indywidualnych charakterystyk, ale wymaga zgromadzenia ≥ 20 pomiarów. Tryb anonimowy minimalizuje ryzyko prywatności (brak `user_id`) kosztem precyzji predykcji.

W praktyce klinicznej zaleca się model hybrydowy: globalny prior + lokalna kalibracja po zgromadzeniu wystarczającej historii.