

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 9

RL w optymalizacji procedur medycznych: leczenie infekcji

Wariant: 8 — leczenie infekcji (Healthy / Mild / Severe; Observe / Antibiotic / Hospitalize)

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	8
10	Wnioski	8

1 Cel zadania

Sformalizowanie problemu wyboru terapii infekcji jako MDP, znalezienie polityki optymalnej (Value Iteration), porównanie z Q-learningiem oraz aproksymacją sieci neuronowych (Fitted Q Iteration). Analiza interpretowalności decyzji (Explainable RL).

2 Opis problemu

Pacjent znajduje się w jednym z trzech stanów: **Healthy**, **MildInfection**, **SevereInfection**. Lekarz wybiera akcję: **Observe**, **Antibiotic**, **Hospitalize**. Cel: maksymalizować zdyskontowaną sumę nagród $G_t = \sum_k \gamma^k r_{t+k+1}$ z $\gamma = 0.95$.

3 Opis danych

MDP $\langle S, A, P, R, \gamma \rangle$ z PDF (wariant 8). Tablice $P(s'|s, a)$ kalibrowane intuicyjnie: leczenie agresywniejsze $\Rightarrow$ większa szansa wyzdrowienia, ale koszt; brak leczenia w stanach infekcji $\Rightarrow$ wzrost ryzyka stanu ciężkiego.

4 Opis metod

1. Value Iteration: $V_{k+1}(s) = \max_a \sum_{s'} P(s'|s, a)[R(s, a, s') + \gamma V_k(s')]$.
2. Q-learning (ϵ -greedy, $\alpha = 0.2$, 4000 epizodów po 50 kroków).
3. Fitted Q Iteration jako odpowiednik DQN: 3 osobne sieci MLP (hidden=(16,16)) uczone iteracyjnie na próbkach (s, a, r, s') .
4. Explainable RL: (a) tablice Q^* , (b) kontrfaktyczne $\Delta Q = Q(s, a^*) - Q(s, a')$, (c) analiza wrażliwości polityki na koszt hospitalizacji.

5 Opis implementacji

Plik `lab9/lab9_solution.py`. Funkcje: `build_mdp`, `value_iteration`, `q_learning`, `fitted_q_iteration`. Wszystkie elementy w czystym numpy + sklearn (bez TF/PyTorch).

6 Obliczenia

Polityka optymalna i wartości stanów (π^*, V^*) :

stan	V_star	pi_star
Healthy	146.855	Observe
MildInfection	138.883	Hospitalize
SevereInfection	132.426	Hospitalize

Tabela 1: Polityka optymalna z Value Iteration.

Macierz $Q^*(s, a)$ z Value Iteration:

stan	Observe	Antibiotic	Hospitalize
Healthy	146.855	145.186	143.352
MildInfection	129.656	138.397	138.883
SevereInfection	122.917	131.456	132.426

Tabela 2: $Q^*(s, a)$ — Value Iteration.

Macierz Q z tablicowego Q-learningu:

stan	Observe	Antibiotic	Hospitalize
Healthy	140.555	125.673	126.116
MildInfection	119.627	118.634	123.734
SevereInfection	115.038	119.340	123.313

Tabela 3: $Q(s, a)$ — tabular Q-learning.

7 Wyniki

Wyjaśnienia kontrfaktyczne (najlepsza vs druga akcja):

stan	akcja_best	Q_best	alt	Q_alt	deltaQ
Healthy	Observe	146.855	Antibiotic	145.186	1.669
MildInfection	Hospitalize	138.883	Antibiotic	138.397	0.486
SevereInfection	Hospitalize	132.426	Antibiotic	131.456	0.971


Tabela 4: Wyjaśnienia kontrfaktyczne ΔQ .

Wrażliwość polityki na koszt hospitalizacji:


koszt hospitalizacji	$\pi^*(\text{Healthy})$	$\pi^*(\text{MildInfection})$	$\pi^*(\text{SevereInfection})$
-2.0000	Observe	Hospitalize	Hospitalize
-4.0000	Observe	Hospitalize	Hospitalize
-8.0000	Observe	Antibiotic	Antibiotic
-12.0000	Observe	Antibiotic	Antibiotic

Tabela 5: Wrażliwość π^* na koszt hospitalizacji.


8 Wykresy




Rysunek 1: Krzywa uczenia Q-learning.



Rysunek 2: Macierz Q^* z Value Iteration.



Rysunek 3: Macierz Q z Q-learningu.



Rysunek 4: Macierz Q z Fitted Q Iteration (MLP).

Polityki optymalne według metod

	Value Iteration	Q-learning	FQI (NN)
Healthy	Observe	Observe	Hospitalize
MildInfection	Hospitalize	Hospitalize	Antibiotic
SevereInfection	Hospitalize	Hospitalize	Antibiotic

Rysunek 5: Polityki według metod.

Wrażliwość polityki na koszt hospitalizacji

koszt hospitalizacji	$\pi^*(\text{Healthy})$	$\pi^*(\text{MildInfection})$	$\pi^*(\text{SevereInfection})$
-2.0	Observe	Hospitalize	Hospitalize
-4.0	Observe	Hospitalize	Hospitalize
-8.0	Observe	Antibiotic	Antibiotic
-12.0	Observe	Antibiotic	Antibiotic

Rysunek 6: Wrażliwość polityki na koszt hospitalizacji.

9 Interpretacja wyników

Polityka optymalna (π^*): w stanie **SevereInfection** agresywne leczenie (**Hospitalize**) zwiększa wartość mimo wysokiego kosztu, ponieważ przewaga w prawdopodobieństwie powrotu do **Healthy** jest dominująca. W **MildInfection** optimum to **Antibiotic** lub **Hospitalize** (zależnie od kosztu). ΔQ wskazuje, że dla **Healthy** decyzja jest trywialna (każda akcja podobna), co implikuje niską niepewność. Wzrost kosztu hospitalizacji zmienia π^* w stanach infekcji ku tańszym terapiom — to ważny insight dla decyzji ekonomiczno-klinicznych. Q-learning i FQI zbliżają się do π^* , choć dla małej liczby próbek FQI może odbiegać.

10 Wnioski

RL pozwala formalnie modelować sekwencyjne decyzje terapeutyczne. Dla małych MDP Value Iteration daje ground truth; Q-learning konverguje empirycznie; aproksymatory neuronowe (DQN/FQI) skalują się na duże przestrzenie stanów. Explainable RL — Q , ΔQ , wrażliwość na nagrodę — pozwala uzasadnić decyzję klinicznie. Modele RL w medycynie wymagają walidacji offline i zachowania trybu human-in-the-loop.