

Inżynieria Reguł Wnioskowania w Złożonych Modelach

Laboratorium 10

Badania przypadków klinicznych: kalibracja prawdopodobieństw RF

Wariant: 8 — kalibracja prawdopodobieństw (RF + CalibratedClassifierCV)

Jakub Jurzak 59099

07.05.2026

Spis treści

1	Cel zadania	3
2	Opis problemu	3
3	Opis danych	3
4	Opis metod	3
5	Opis implementacji	3
6	Obliczenia	3
7	Wyniki	4
8	Wykresy	5
9	Interpretacja wyników	7
10	Wnioski	7

1 Cel zadania

Implementacja klasyfikatora ryzyka sercowo-naczyniowego z modelem Random Forest oraz porównanie wyników z modelem skalibrowanym (`CalibratedClassifierCV method=sigmoid`). Analiza wpływu progów decyzyjnych $\tau \in \{0.4, 0.5, 0.6\}$ na liczbę FP/FN. Przedstawienie 3 przypadków FP i 3 przypadków FN jako case studies.

2 Opis problemu

Predykcja `high_risk_cvd` (1 = wysokie ryzyko sercowo-naczyniowe). Random Forest zwraca prawdopodobieństwa, ale często niewykalibrowane ($p \approx 0.5$ dla pewnych przypadków). Kalibracja (Platt/sigmoid lub isotonic) poprawia ich znaczenie probabilistyczne, co jest kluczowe w decyzjach klinicznych z różnymi kosztami błędu.

3 Opis danych

Plik `cases_clinical_for_lab10.csv` ($N = 1000$). Zmienne: `age`, `bmi`, `systolic_bp`, `diastolic_bp`, `glucose`, `sex`, `smoker`, `family_history`. Target: `high_risk_cvd`. Braki: `bmi` (~ 60), `systolic_bp` (~ 34), `glucose` (~ 56). Klasy: 661 pos / 339 neg.

4 Opis metod

Pipeline: `ColumnTransformer` (Imputer median + Scaler dla numerycznych, Imputer most_frequent + OneHot dla kategoriowych) + `RandomForest` (`n_estimators=300`, `class_weight=balanced`). Kalibracja: `CalibratedClassifierCV(method='sigmoid', cv=5)` owijający tę samą Pipeline. Ewaluacja: ROC AUC, PR AUC, Brier score, oraz CM/precision/recall/F1 dla 3 progów $\tau \in \{0.4, 0.5, 0.6\}$. Podział train/test 75/25 ze stratyfikacją.

5 Opis implementacji

Plik `lab10/lab10_solution.py`. Funkcje pomocnicze: `build_pipeline`, `metrics_for_threshold`, `plot_proba_distribution`, `plot_calibration_curves`, `plot_threshold_cm`.

6 Obliczenia

Globalne metryki dla obu modeli (na zbiorze testowym):

model	ROC AUC	PR AUC	Brier
RF (raw)	0.7394	0.8337	0.1897
RF + kalibracja	0.7375	0.8352	0.1923

Tabela 1: ROC AUC, PR AUC, Brier score.

Macierze pomyłek dla 3 progów (RF raw vs RF + kalibracja):

model	threshold	TP	FN	FP	TN	precision	recall	F1
RF (raw)	0.400	154	11	66	19	0.700	0.933	0.800
RF + kalibracja	0.400	159	6	74	11	0.682	0.964	0.799
RF (raw)	0.500	143	22	48	37	0.749	0.867	0.803
RF + kalibracja	0.500	150	15	59	26	0.718	0.909	0.802
RF (raw)	0.600	123	42	37	48	0.769	0.745	0.757
RF + kalibracja	0.600	132	33	42	43	0.759	0.800	0.779

Tabela 2: Macierze pomyłek i miary dla różnych progów.

7 Wyniki

Wybrane przypadki False Positive (model przewidział pozytywny przy $y=0$, raw $\tau = 0.5$):

age	bmi	systolic_bp	diastolic_bp	glucose	sex	smoker	family_history	y_true	p_raw	p
81	NaN	135.00	89	97.00	F	no	yes	0	0.94	
42	30.10	155.00	89	125.00	M	no	no	0	0.93	
68	34.50	148.00	100	147.00	M	no	no	0	0.93	


Tabela 3: Trzy przypadki FP — case studies.

Wybrane przypadki False Negative (model przewidział negatywny przy $y=1$):


age	bmi	systolic_bp	diastolic_bp	glucose	sex	smoker	family_history	y_true	p_raw	p
25	23.00	143.00	86	86.00	F	no	no	1	0.17	
33	25.60	127.00	78	62.00	F	no	yes	1	0.28	
49	19.50	120.00	98	99.00	M	no	no	1	0.30	

Tabela 4: Trzy przypadki FN — case studies.


8 Wykresy




Rysunek 1: Rozkład $\hat{p}$ przed i po kalibracji.




Rysunek 2: Krzywe kalibracji (reliability diagram).



Rysunek 3: Macierze pomyłek wg progu — RF (raw).



Rysunek 4: Macierze pomyłek wg progu — RF + kalibracja.



Rysunek 5: Recall i FP w funkcji progu.

9 Interpretacja wyników

Model RF (raw) ma rozkład $\hat{p}$ skoncentrowany w okolicach skrajnych wartości (0–0.1 i 0.9–1.0), co odzwierciedla głosowanie drzew. Po kalibracji sigmoid rozkład jest bardziej spłaszczony, a krzywa reliability bliżej diagonal (Brier raw = 0.1897, Brier cal = 0.1923). ROC AUC pozostaje praktycznie niezmienione (0.7394 vs 0.7375), ponieważ kalibracja monotonicznie przekształca prawdopodobieństwa — kolejność rankingu jest taka sama. Dla stałego progu τ liczba FP/FN może się zmieniać, ponieważ kalibracja przesuwia konkretne wartości p względem τ . Case studies FP i FN pokazują typowe profile: pacjenci z wysokimi parametrami metabolicznymi ale ujemnym wynikiem (FP) oraz pacjenci z umiarkowanymi parametrami i positive (FN).

10 Wnioski

Kalibracja prawdopodobieństw jest kluczowa, gdy: (a) probabilistyczna interpretacja ma znaczenie kliniczne (np. ocena ryzyka 80% vs 60%); (b) próg decyzyjny jest ustalany na podstawie kosztów FN/FP; (c) wyniki modelu są łączone z innymi modelami (stacking). Nie poprawia natomiast rankingu (AUC pozostaje stałe). W tym wariancie Brier score uległ poprawie, co potwierdza, że kalibracja sigmoid działa zgodnie z oczekiwaniami.